

Escenarios por tipo de información

Predicción del voto presidencial 2020 (Trump vs Biden) — ANES Social Media 2020-2022

Cada escenario agrega un **tipo** de información, ordenado por su “explicitud política” (validado por la correlación de cada bloque con el voto). La métrica es **accuracy con XGBoost, holdout repetido x5**. La idea central: el score sube por el **tipo** de información, no por la cantidad de variables.

Escenario	+vars	Σ vars	Accuracy	Aporte
Apolítico real	+75	75	0,750	piso
+ conducta polarizada	+7	82	0,801	+0,05
+ afecto identitario	+8	90	0,851	+0,05
+ posiciones de issues	+14	104	0,926	+0,075
+ ideología explícita	+6	110	0,933	+0,01
+ actitudes a candidatos	+232	342	0,971	+0,04

Σ vars = variables acumuladas. El modelo final llega hasta el nivel 3c (110 variables); el nivel 4 es solo referencia (near-leakage).

■ 1 · Apolítico real · accuracy 0,750

Información de “**quién sos**” sin contenido político, en tres familias:

- **Demografía:** edad, género, raza/etnia, educación, ingreso, estado civil, región, religión, si es evangélico (*profile_age*, *profile_raceethnicity*, *profile_educ5*, *profile_income*, *profile_relig*, *profile_born*).
- **Salud factual:** impacto del COVID en trabajo/finanzas/salud, salud general autopercibida, escala de depresión (*w2covid_work*, *w2covid_fin*, *w3genhealth*, *w3phq92*).
- **Uso de redes y medios:** qué plataformas usa (Facebook, Instagram, TikTok, Twitter, YouTube) y por dónde se informa (*fbuser*, *w3twit*, *w3tube*, *w3news*, *w3newskeepup*).

Por qué: Es el piso “honesto”: su correlación con el voto es ≈ 0 . Saber edad, raza, educación y qué redes usás deja **mucho sin explicar** (0,75).

■ 2 · + conducta polarizada · accuracy 0,801

Comportamiento que **parece** apolítico pero en 2020 se politizó:

- **Conducta en pandemia:** cuánto se juntaba con gente / salía (*w2covid_gather*, *w2covid_out*).
- **Empatía:** tendencia a ponerse en el lugar del otro (*w2emp_place*).
- **Discernimiento de noticias** y consumo de información política (*w2discern*, *w3discern*, *w2p5*, *w3pe*).

Por qué: No es ideología declarada, pero en el clima de 2020 estas conductas correlacionan 0,2–0,3 con el voto (el comportamiento frente al COVID se volvió señal partidaria). Suma +5 puntos.

■ 3a · + afecto identitario / cultura · accuracy 0,851

Termómetros de sentimiento (0–100) hacia **grupos sociales y culturales**:

- gays, personas trans, feministas, ateos, musulmanes (*w2ftgay*, *w2fttrans*, *w2ftfeminists*, *w3ftatheists*, *w3ftmuslims*).

Por qué: Actitudes culturales estables —no “política” en sentido estricto— pero correlacionan 0,4–0,5. Cómo te sentís hacia grupos identitarios ya predice bastante. Suma +5 puntos.

■ 3b · + posiciones de issues · accuracy 0,926

Opiniones **concretas sobre temas de política pública**:

- **Termómetros económico-institucionales**: socialistas, capitalistas, policía, periodistas (*w2ftsocialists*, *w2ftcapitalists*, *w2ftpolicie*, *w2ftjournal*).
- **Posiciones**: control de armas, cambio climático, aborto, Obamacare/ACA, deportación-inmigración (*w2gundiff*, *w2c_self*, *w3abortion*, *w2aca*, *w2deport*).

Por qué: Acá está el salto grande: +7,5 puntos con apenas 14 variables. Correlación 0,5–0,66 con el voto. Las opiniones sobre issues concretos son el predictor decisivo, no la demografía.

■ 3c · + ideología explícita · accuracy 0,933

La etiqueta ideológica más directa:

- **Autoubicación izquierda–derecha** (*w2lcself*, *w3lcself*).
- **Cosmovisión simbólica**: resentimiento racial y sexismo moderno (*w2rr1*, *w2rr2*, *w2w1*, *w2w2*).

Por qué: Correlación altísima (*lcself* $\approx$ 0,73), pero **redundante**: solo +1 punto sobre los issues. “Soy conservador” ya está implícito en qué opina la persona sobre aborto, clima y armas.

■ 4 · + actitudes a candidatos (near-leakage) · accuracy 0,971

Todo el resto de variables pre-elección, incluidas las que están **peligrosamente cerca** de preguntar el voto:


- termómetros a Trump / Biden / partidos, intención de voto, “qué partido es mejor en X”, aprobación presidencial.

Por qué: Se incluye solo como **techo de referencia**. Son 232 variables adicionales que aportan apenas +4 puntos: confirma que la señal útil ya estaba en los issues. **No se usan en el modelo final** por riesgo de leakage.


Variables más importantes por escenario

Importancia por **permutación** (no MDI): se mide cuántos puntos de accuracy se **pierden** al desordenar al azar cada variable en el conjunto de test. Es honesta con la redundancia —una variable cuya información ya está en otra no recibe crédito—. XGBoost, n_repeats=10. La barra es relativa al máximo de cada escenario.


■ Apolítico real · accuracy 0,750




■ + conducta polarizada · accuracy 0,801




■ + afecto identitario · accuracy 0,851




■ + posiciones de issues · accuracy 0,926



■ + ideología explícita · accuracy 0,933



■ + actitudes a candidatos · accuracy 0,971



Lectura: en el nivel **apolítico** mandan el ser **evangélico** y la **raza/etnia** (la espina dorsal sociológica del voto). Al sumar issues, los **termómetros a policía, periodistas y socialistas** y el **control de armas** pasan al frente. En **near-leakage** las importancias se **desploman** (~0,3 pts): con 342 variables todo está tan duplicado que permutar una sola casi no mueve el accuracy.

Nivel 4 “limpio”: sin leaks ni paradata

El nivel 4 original incluía **basura** que se colaba: **paradata** (tiempos de respuesta *total_time_** y orden de los termómetros *ft_order_**) y **leak directo** del voto (intención de voto *vote20d1*, voto a Cámara *voterep*, la primaria demócrata). Quitamos **60 variables** (46 paradata + 14 leak) y mantuvimos los **termómetros sustantivos**. Resultado:

Escenario	Variables	Accuracy
Nivel 4 original (con leaks + paradata)	342	0,971
Nivel 4 limpio (sin leaks/paradata, con termómetros)	282	0,971

Idéntico (0,971 = 0,971). Las 60 variables eliminadas no aportaban **nada**: la paradata era ruido y el leak directo era redundante con los termómetros. Confirma que sacar esa basura es gratis.

■ Top variables del nivel 4 limpio · accuracy 0,971

Term. a Trump	■■■■■■■■■■■ 1.4
Aprobación a Trump (presidente)	■■■■■ 0.6
Term. a Biden	■■■■■ 0.6
Term. a Demócratas	■■■■ 0.4
Destitución de Trump (impeachment)	■■■■ 0.4
Term. a inmigrantes	■■■ 0.3
Term. a Sanders	■■■ 0.2
Manejo del COVID en EE.UU.	■■■ 0.2
“Trump se preocupa por mí”	■■■ 0.2
Identificación partidaria	■■■ 0.2
Estereotipo: ¿demócratas inteligentes?	■■■ 0.2
Aprobación a Trump (coronavirus)	■■■ 0.2

Ahora el ranking es honesto y se entiende: domina el **termómetro a Trump** (−1,4 pts), seguido de la **aprobación a Trump** y los termómetros a **Biden / Demócratas**. **Ojo**: estos siguen siendo *proxies de preferencia* (sentir frío/calor por Trump es casi declarar el voto). Por eso el **modelo final del proyecto no usa el nivel 4**: es el techo de referencia, no un predictor legítimo.

Resumen visual

