

Escenarios por tipo de información

Predicción del voto presidencial 2020 (Trump vs Biden) — ANES Social Media 2020-2022

Cada escenario agrega un **tipo** de información, ordenado por su “explicitud política” (validado por la correlación de cada bloque con el voto). La métrica es **accuracy con XGBoost, holdout repetido x5**. La idea central: el score sube por el **tipo** de información, no por la cantidad de variables.

Escenario	+vars	Σ vars	Accuracy	Aporte
Apolítico real	+75	75	0,750	piso
+ conducta polarizada	+7	82	0,801	+0,05
+ afecto identitario	+8	90	0,851	+0,05
+ posiciones de issues	+14	104	0,926	+0,075
+ ideología explícita	+6	110	0,933	+0,01
+ actitudes a candidatos	+232	342	0,971	+0,04

Σ vars = variables acumuladas. El modelo final llega hasta el nivel 3c (110 variables); el nivel 4 es solo referencia (near-leakage).

■ 1 · Apolítico real · accuracy 0,750

Información de “**quién sos**” sin contenido político, en tres familias:

- **Demografía:** edad, género, raza/etnia, educación, ingreso, estado civil, región, religión, si es evangélico (*profile_age, profile_raceethnicity, profile_educ5, profile_income, profile_relig, profile_born*).
- **Salud factual:** impacto del COVID en trabajo/finanzas/salud, salud general autopercibida, escala de depresión (*w2covid_work, w2covid_fin, w3genhealth, w3phq92*).
- **Uso de redes y medios:** qué plataformas usa (Facebook, Instagram, TikTok, Twitter, YouTube) y por dónde se informa (*fbuser, w3twit, w3tube, w3newsocial, w3newskeepup*).

Por qué: Es el piso “honesto”: su correlación con el voto es ≈ 0 . Saber edad, raza, educación y qué redes usás deja **mucho sin explicar** (0,75).

■ 2 · + conducta polarizada · accuracy 0,801

Comportamiento que **parece** apolítico pero en 2020 se politizó:

- **Conducta en pandemia:** cuánto se juntaba con gente / salía (*w2covid_gather, w2covid_out*).
- **Empatía:** tendencia a ponerse en el lugar del otro (*w2emp_place*).
- **Discernimiento de noticias** y consumo de información política (*w2discern, w3discern, w2p5, w3pe*).

Por qué: No es ideología declarada, pero en el clima de 2020 estas conductas correlacionan 0,2–0,3 con el voto (el comportamiento frente al COVID se volvió señal partidaria). Suma +5 puntos.

■ 3a · + afecto identitario / cultura · accuracy 0,851

Termómetros de sentimiento (0–100) hacia **grupos sociales y culturales**:

- gays, personas trans, feministas, ateos, musulmanes (*w2ftgay, w2fttrans, w2ftfeminists, w3ftatheists, w3ftmuslims*).

Por qué: Actitudes culturales estables —no “política” en sentido estricto— pero correlacionan 0,4–0,5. Cómo te sentís hacia grupos identitarios ya predice bastante. Suma +5 puntos.

■ 3b · + posiciones de issues · accuracy 0,926

Opiniones **concretas** sobre temas de política pública:

- **Termómetros económico-institucionales:** socialistas, capitalistas, policía, periodistas (*w2ftsocalists*, *w2ftcapitalists*, *w2ftpolicie*, *w2ftjournal*).
- **Posiciones:** control de armas, cambio climático, aborto, Obamacare/ACA, deportación-inmigración (*w2gundiff*, *w2c_self*, *w3abortion*, *w2aca*, *w2deport*).

Por qué: Acá está el salto grande: +7,5 puntos con apenas 14 variables. Correlación 0,5–0,66 con el voto. Las opiniones sobre issues concretos son el predictor decisivo, no la demografía.

■ 3c · + ideología explícita · accuracy 0,933

La etiqueta ideológica más directa:

- **Autoubicación izquierda–derecha** (*w2lcself*, *w3lcself*).
- **Cosmovisión simbólica:** resentimiento racial y sexismo moderno (*w2rr1*, *w2rr2*, *w2w1*, *w2w2*).

Por qué: Correlación altísima (*lcself* $\approx$ 0,73), pero **redundante:** solo +1 punto sobre los issues. “Soy conservador” ya está implícito en qué opina la persona sobre aborto, clima y armas.


■ 4 · + actitudes a candidatos (near-leakage) · accuracy 0,971

Todo el resto de variables pre-elección, incluidas las que están **peligrosamente cerca** de preguntar el voto:

- termómetros a Trump / Biden / partidos, intención de voto, “qué partido es mejor en X”, aprobación presidencial.

Por qué: Se incluye solo como **techo de referencia**. Son 232 variables adicionales que aportan apenas +4 puntos: confirma que la señal útil ya estaba en los issues. **No se usan en el modelo final** por riesgo de leakage.

Resumen visual



La pendiente es empinada al pasar a issues (pocas variables, gran salto) y casi plana después (muchas variables, poco aporte).