

Escenarios por tipo de información

Predicción del voto presidencial 2020 (Trump vs Biden) — ANES Social Media 2020-2022

Cada escenario agrega un **tipo** de información, ordenado por su “explicitud política” (validado por la correlación de cada bloque con el voto). La métrica es **accuracy con XGBoost, holdout repetido x5**. La idea central: el score sube por el **tipo** de información, no por la cantidad de variables.

Escenario	+vars	Σ vars	Accuracy	Aporte
Apolítico real	+75	75	0,750	piso
+ conducta polarizada	+7	82	0,801	+0,05
+ afecto identitario	+8	90	0,851	+0,05
+ posiciones de issues	+14	104	0,926	+0,075
+ ideología explícita	+6	110	0,933	+0,01
+ actitudes a candidatos	+232	342	0,971	+0,04

Σ vars = variables acumuladas. El modelo final llega hasta el nivel 3c (110 variables); el nivel 4 es solo referencia (near-leakage).

■ 1 · Apolítico real · accuracy 0,750

Información de “**quién sos**” sin contenido político, en tres familias:

- **Demografía:** edad, género, raza/etnia, educación, ingreso, estado civil, región, religión, si es evangélico (*profile_age, profile_raceethnicity, profile_educ5, profile_income, profile_relig, profile_born*).
- **Salud factual:** impacto del COVID en trabajo/finanzas/salud, salud general autopercibida, escala de depresión (*w2covid_work, w2covid_fin, w3genhealth, w3phq92*).
- **Uso de redes y medios:** qué plataformas usa (Facebook, Instagram, TikTok, Twitter, YouTube) y por dónde se informa (*fbuser, w3twit, w3tube, w3newsonline, w3newskeepup*).

Por qué: Es el piso “honesto”: su correlación con el voto es ≈ 0 . Saber edad, raza, educación y qué redes usás deja **mucho sin explicar** (0,75).

■ 2 · + conducta polarizada · accuracy 0,801

Comportamiento que **parece** apolítico pero en 2020 se politizó:

- **Conducta en pandemia:** cuánto se juntaba con gente / salía (*w2covid_gather, w2covid_out*).
- **Empatía:** tendencia a ponerse en el lugar del otro (*w2emp_place*).
- **Discernimiento de noticias** y consumo de información política (*w2discern, w3discern, w2p5, w3pe*).

Por qué: No es ideología declarada, pero en el clima de 2020 estas conductas correlacionan 0,2–0,3 con el voto (el comportamiento frente al COVID se volvió señal partidaria). Suma +5 puntos.

■ 3a · + afecto identitario / cultura · accuracy 0,851

Termómetros de sentimiento (0–100) hacia **grupos sociales y culturales**:

- gays, personas trans, feministas, ateos, musulmanes (*w2ftgay, w2fttrans, w2ftfeminists, w3ftatheists, w3ftmuslims*).

Por qué: Actitudes culturales estables —no “política” en sentido estricto— pero correlacionan 0,4–0,5. Cómo te sentís hacia grupos identitarios ya predice bastante. Suma +5 puntos.

■ 3b · + posiciones de issues · accuracy 0,926

Opiniones **concretas sobre temas de política pública**:

- **Termómetros económico-institucionales**: socialistas, capitalistas, policía, periodistas (*w2ftsocialists*, *w2ftcapitalists*, *w2ftpolicie*, *w2ftjournal*).
- **Posiciones**: control de armas, cambio climático, aborto, Obamacare/ACA, deportación-inmigración (*w2gundiff*, *w2c_self*, *w3abortion*, *w2aca*, *w2deport*).

Por qué: Acá está el salto grande: +7,5 puntos con apenas 14 variables. Correlación 0,5–0,66 con el voto. Las opiniones sobre issues concretos son el predictor decisivo, no la demografía.

■ 3c · + ideología explícita · accuracy 0,933

La etiqueta ideológica más directa:

- **Autoubicación izquierda–derecha** (*w2lcself*, *w3lcself*).
- **Cosmovisión simbólica**: resentimiento racial y sexismo moderno (*w2rr1*, *w2rr2*, *w2w1*, *w2w2*).

Por qué: Correlación altísima ($lcself \approx 0,73$), pero **redundante**: solo +1 punto sobre los issues. “Soy conservador” ya está implícito en qué opina la persona sobre aborto, clima y armas.

■ 4 · + actitudes a candidatos (near-leakage) · accuracy 0,971

Todo el resto de variables pre-elección, incluidas las que están **peligrosamente cerca** de preguntar el voto:


- termómetros a Trump / Biden / partidos, intención de voto, “qué partido es mejor en X”, aprobación presidencial.

Por qué: Se incluye solo como **techo de referencia**. Son 232 variables adicionales que aportan apenas +4 puntos: confirma que la señal útil ya estaba en los issues. **No se usan en el modelo final** por riesgo de leakage.


Variables más importantes por escenario

Importancia por **permutación** (no MDI): se mide cuántos puntos de accuracy se **pierden** al desordenar al azar cada variable en el conjunto de test. Es honesta con la redundancia —una variable cuya información ya está en otra no recibe crédito—. XGBoost, n_repeats=10. La barra es relativa al máximo de cada escenario.


■ Apolítico real · accuracy 0,750




■ + conducta polarizada · accuracy 0,801




■ + afecto identitario · accuracy 0,851




■ + posiciones de issues · accuracy 0,926



■ + ideología explícita · accuracy 0,933



■ + actitudes a candidatos · accuracy 0,971



Lectura: en el nivel **apolítico** mandan el ser **evangélico** y la **raza/etnia** (la espina dorsal sociológica del voto). Al sumar issues, los **termómetros a policía, periodistas y socialistas** y el **control de armas** pasan al frente. En **near-leakage** las importancias se **desploman** (~0,3 pts): con 342 variables todo está tan duplicado que permutar una sola casi no mueve el accuracy.

Nivel 4 “limpio”: sin leaks ni paradata

El nivel 4 original incluía **basura** que se colaba: **paradata** (tiempos de respuesta *total_time_** y orden de los termómetros *ft_order_**) y **leak directo** del voto (intención de voto *vote20d1*, voto a Cámara *voterep*, la primaria demócrata). Quitamos **60 variables** (46 paradata + 14 leak) y mantuvimos los **termómetros sustantivos**. Resultado:

Escenario	Variables	Accuracy
Nivel 4 original (con leaks + paradata)	342	0,971
Nivel 4 limpio (sin leaks/paradata, con termómetros)	282	0,971


Idéntico (0,971 = 0,971). Las 60 variables eliminadas no aportaban **nada**: la paradata era ruido y el leak directo era redundante con los termómetros. Confirma que sacar esa basura es gratis.

■ Top variables del nivel 4 limpio · accuracy 0,971

Term. a Trump	■■■■■■■■■■■ 1.4
Aprobación a Trump (presidente)	■■■■■ 0.6
Term. a Biden	■■■■■ 0.6
Term. a Demócratas	■■■■ 0.4
Destitución de Trump (impeachment)	■■■■ 0.4
Term. a inmigrantes	■■■ 0.3
Term. a Sanders	■■■ 0.2
Manejo del COVID en EE.UU.	■■■ 0.2
“Trump se preocupa por mí”	■■■ 0.2
Identificación partidaria	■■■ 0.2
Estereotipo: ¿demócratas inteligentes?	■■■ 0.2
Aprobación a Trump (coronavirus)	■■■ 0.2

Ahora el ranking es honesto y se entiende: domina el **termómetro a Trump** (−1,4 pts), seguido de la **aprobación a Trump** y los termómetros a **Biden / Demócratas**. **Ojo**: estos siguen siendo *proxies de preferencia* (sentir frío/calor por Trump es casi declarar el voto). Por eso el **modelo final del proyecto no usa el nivel 4**: es el techo de referencia, no un predictor legítimo.

Resumen visual



¿Y si el voto tiene más de dos clases?

Hasta acá modelamos **Trump vs Biden** (binario). Probamos dos variantes multiclase y **ninguna funciona bien** — por la misma razón: el **desbalance de clases**. El *accuracy* engaña (queda cerca de “adivinar siempre la mayoría”); el **f1_macro** y el **recall por clase** lo exponen. Modelo: HistGradientBoosting, holdout ×5.

1 · Voto general con la clase “Otro” (3 clases)

Trump / Biden / Otro. accuracy **0.935** · f1_macro **0.676** · baseline “siempre la mayoría” 0.565.

Clase	n (casos)	% del total	Recall (acierto)
Biden	2561	56.5%	0.98
Trump	1801	39.7%	0.96
Otro	171	3.8%	0.07

El accuracy alto (0,935) es un **espejismo**: viene de que Trump y Biden se predicen casi perfecto. La clase **“Otro” (171 casos, 3,8%) tiene recall 0,07** — el modelo casi nunca la acierta. Los terceros partidos son ~2% del electorado y no tienen un perfil propio: se reparten entre los dos grandes. **Por eso modelamos el problema como binario.**

2 · Primaria demócrata (vote20cand, 7 candidatos)

Biden / Sanders / Warren / Buttigieg / Klobuchar / Bloomberg / Otro. accuracy **0.697** · f1_macro **0.234** · baseline 0.629.

Clase	n (casos)	% del total	Recall (acierto)
Biden	1628	62.9%	0.93
Sanders	482	18.6%	0.55
Warren	173	6.7%	0.07
Otro	108	4.2%	0.22
Buttigieg	88	3.4%	0.00
Klobuchar	56	2.2%	0.00
Bloomberg	52	2.0%	0.00

Acá el f1_macro se **derrumba a 0,23**. El modelo solo aprende **Biden** (recall 0,93) y a medias **Sanders** (0,55); **Bloomberg, Buttigieg y Klobuchar tienen recall 0,00** — con <90 casos cada uno, no hay con qué aprenderlos. La primaria *fue*, en los hechos, Biden vs Sanders. **Ninguna técnica rescata una clase de 52 ejemplos solapada con una mayoría de 1.628.**

Lección: con clases minoritarias el accuracy miente; hay que mirar f1_macro y recall por clase. El cuello de botella es la **cantidad de casos**, no el método.

Predecir el voto vs predecir el partidismo

¿Es más fácil predecir **a quién votó** o **con qué partido se identifica** (pid7x)? Con las **mismas features** (solo demografía + uso de redes, sin actitudes políticas) y el mismo modelo (XGBoost, holdout ×5), comparamos. Sin la clase “Otro” del voto.

Qué se predice	Clases	n	Accuracy	f1_macro
Voto (Trump vs Biden)	2	4362	0.727 ± 0.011	0.715
Partidismo (Dem vs Rep)	2	5097	0.718 ± 0.013	0.714
Partidismo (Dem/Indep/Rep)	3	5743	0.641 ± 0.013	0.490

(features = 41 variables de demografía + redes)

Voto (0,727) y partidismo binario (0,718) dan prácticamente lo mismo —la diferencia cae dentro del desvío—. No es casualidad: **voto e identidad partidaria coinciden en ~94% de las personas** (correlación de Spearman 0,78), así que para un modelo son **casi la misma variable**. El techo de ~0,72 no es una propiedad “del voto” ni “del partidismo”: es el **límite de lo que la demografía sola puede decir**.

Cuando se agregan los **independientes** (3 clases), el accuracy cae a **0,641** y el f1_macro a 0,49: los independientes no tienen un perfil demográfico propio (están “en el medio”), así que son los más difíciles de clasificar — el mismo fenómeno que veíamos en los votantes cruzados.

Optimización de hiperparámetros

Los **parámetros** los aprende el modelo de los datos (los cortes de los árboles); los **hiperparámetros** se fijan antes y controlan *cómo* aprende (profundidad, regularización...). Optimizarlos = probar combinaciones y quedarse con la que mejor generaliza.

El protocolo: split 60 / 20 / 20

Partimos en **tres**: **train (60%)** para entrenar cada candidato, **validation (20%)** para elegir el mejor, y **test (20%)** para el número final. **El test no se toca durante la búsqueda.** Si eligiéramos los hiperparámetros mirando el test, nos sobreajustaríamos a él y el resultado saldría optimista; el *validation* es el “test de mentira” que sí podemos mirar, y el test real queda virgen para un reporte honesto.

La búsqueda: random search + early stopping

Probamos **40 combinaciones al azar** del espacio (no todas: el grid completo son 8.640). El *random search* es más eficiente que el grid porque muchos hiperparámetros casi no influyen. El número de árboles no se busca a mano: se fija alto (2.000) y el **early stopping** lo corta solo cuando el error en *validation* deja de mejorar (50 rondas).

Hiperparámetro	Valores probados	Qué controla
max_depth	2, 3, 4, 6, 8	profundidad → interacciones que capta
learning_rate	0,01 – 0,1	cuánto aporta cada árbol
min_child_weight	1, 3, 5, 10	mínimo de datos por hoja (poda)
subsample	0,6 / 0,8 / 1,0	fracción de filas por árbol
colsample_bytree	0,6 / 0,8 / 1,0	fracción de columnas por árbol
reg_lambda	0, 1, 2, 5	regularización L2
reg_alpha	0, 0,5, 1	regularización L1

Resultados (XGBoost, reporte en test intacto)

Set de features	default	tuneado	val	Δ
Completo (techo ~0,97)	0.964	0.966	0.977	+0.001
Demografía+redes (~0,72)	0.726	0.729	0.732	+0.002

Mejor config completo: depth=2, lr=0.1, min_child=1, sub=0.8, col=0.6, λ =2.0, α =1.0, árboles=114.

Mejor config demo+redes: depth=2, lr=0.1, min_child=5, sub=0.6, col=0.6, λ =5.0, α =0.0, árboles=185.

Tres conclusiones

1 · El tuning mueve milésimas (+0,002). En el techo alto y en el bajo por igual: el límite es la **señal de los datos**, no los hiperparámetros.

2 · La búsqueda eligió sola el modelo más simple (max_depth = 2 en ambos sets). Con poca estructura que exprimir, los árboles chatos ganan — y el early stopping bajó los árboles de 500 a 114/185.

3 · Validation sobreestima. En el set completo, validation dio **0.977** pero el test honesto fue **0.966** (~1 punto de diferencia). El val está “elegido” (es el máximo de 40 candidatos), así que infla; por eso se reporta el **test intacto**. Esto es justo lo que el protocolo 60/20/20 está diseñado para evitar.