

¿Qué determina el voto?

Predicción del voto presidencial 2020 (EE.UU.) a partir de perfil, uso de redes y actitudes

— ANES Special Study 2020-2022 (Social Media) —

Tomás Gómez Pizarro · Mikael Rodríguez

Ciencia de Datos 2026 — FAMAF, Universidad Nacional de Córdoba

Junio de 2026

github.com/tomasgomezpizarro/proyecto-datos

Resumen

Predecimos el **voto presidencial 2020 (Trump vs Biden)** sobre la encuesta ANES Special Study 2020-2022 (5.750 encuestados, 914 variables) y, más que maximizar el acierto, estudiamos **qué tipo de información** lo determina. El desafío central es metodológico: separar predictores legítimos de *fugas* (*leakage*) en cientos de variables. Construimos una **escalera de escenarios** ordenada por “explicitud política” y medimos cuánto aporta cada bloque de información.

Hallazgo principal: la **demografía sola predice poco** (~0,75); el salto decisivo lo dan las **posiciones sobre issues** (aborto, clima, armas), que llevan el accuracy a **0,93**. La ideología auto-declarada resulta redundante una vez conocidos los issues. El **tuning de hiperparámetros, la elección de algoritmo y la cantidad de datos casi no mueven la aguja**: el cuello de botella es la información, no el modelo. El error remanente (~3-6%) es irreducible —los **votantes cruzados**, que votan contra su propio perfil—.

Datos y metodología

Los datos

ANES Special Study 2020-2022 (Social Media): 5.750 encuestados × 914 variables, en tres olas (pre-elección, post-elección y seguimiento 2021-22). Los faltantes vienen codificados con negativos (−1...−9) → convertidos a *NaN*. Las respuestas son códigos ordinales, no magnitudes: los modelos de árboles los toleran; los lineales se usan como baseline. Por defecto se excluyen las variables de las olas 2 y 3 (medidas igual o después del voto).

Un hallazgo previo: la label estaba mal identificada

El primer candidato a variable objetivo, *vote20cand*, resultó ser la **primaria demócrata** (Biden vs Sanders vs Warren...), no la elección general. Lo detectamos porque un binario “Biden vs Trump” daba apenas 86% y porque los códigos no cerraban: al decodificarlos con los termómetros de sentimiento, *todos* los grupos resultaban pro-Biden. La variable correcta es **w2presvtwho** (Trump 1.801 · Biden 2.561 · Otro 171), verificada con termómetros. **Lección: desconfiar de un número que “hace ruido” y verificar el significado contra el codebook.**

La taxonomía de leakage (el corazón metodológico)

Con 914 variables, el problema central es separar predictores legítimos de *fugas*. Lo decidimos por la pregunta: “¿es causa o consecuencia del voto?”

Tipo	Ejemplos	Decisión
Leakage directo	a quién votó, voto a diputados/senadores	excluir
Consecuencia del voto	aprobación post, emociones del resultado	excluir
Percepción partidaria	estado de la economía, confianza en instituciones	excluir
Proxy de preferencia	“qué partido es mejor en X”, termómetros a candidatos	excluir
Leakage temporal	toda variable de la ola 2/3	excluir
Predisposición estable	valores, afecto a grupos, ideología	USAR
Apolítico	demografía, salud factual, uso de redes	USAR

Matiz clave: “medido después de la elección” **no** es lo mismo que *leakage*. Una actitud estable (visión sobre capitalistas/gays, resentimiento racial) es **anterior y causal**, aunque se haya preguntado en la ola post-electoral.

Validación

Métricas: **accuracy + f1_macro** (por el desbalance) y matriz de confusión / recall por clase. Estimación con **holdout repetido ×5** (media ± desvío): no se lee el tercer decimal de un único split (su error de muestreo es ≈ ±0,6-1,3%). Modelo principal: **XGBoost**; se comparan Regresión Logística, LDA y Random Forest como referencia.

Escenarios por tipo de información

Predicción del voto presidencial 2020 (Trump vs Biden) — ANES Social Media 2020-2022

Cada escenario agrega un **tipo** de información, ordenado por su “explicitud política” (validado por la correlación de cada bloque con el voto). La métrica es **accuracy con XGBoost, holdout repetido x5**. La idea central: el score sube por el **tipo** de información, no por la cantidad de variables.

Escenario	+vars	Σ vars	Accuracy	Aporte
Apolítico real	+75	75	0,750	piso
+ conducta polarizada	+7	82	0,801	+0,05
+ afecto identitario	+8	90	0,851	+0,05
+ posiciones de issues	+14	104	0,926	+0,075
+ ideología explícita	+6	110	0,933	+0,01
+ actitudes a candidatos	+172	282	0,971	+0,04

Σ vars = variables acumuladas. El modelo final llega hasta el nivel 3c (110 variables); el nivel 4 es solo referencia (near-leakage).

■ 1 · Apolítico real · accuracy 0,750

Información de “**quién sos**” sin contenido político, en tres familias:

- **Demografía:** edad, género, raza/etnia, educación, ingreso, estado civil, región, religión, si es evangélico (*profile_age, profile_raceethnicity, profile_educ5, profile_income, profile_relig, profile_born*).
- **Salud factual:** impacto del COVID en trabajo/finanzas/salud, salud general autopercibida, escala de depresión (*w2covid_work, w2covid_fin, w3genhealth, w3phq92*).
- **Uso de redes y medios:** qué plataformas usa (Facebook, Instagram, TikTok, Twitter, YouTube) y por dónde se informa (*fbuser, w3twit, w3tube, w3newsonline, w3newskeepup*).

Por qué: Es el piso “honesto”: su correlación con el voto es ≈ 0 . Saber edad, raza, educación y qué redes usás deja **mucho sin explicar** (0,75).

■ 2 · + conducta polarizada · accuracy 0,801

Comportamiento que **parece** apolítico pero en 2020 se politizó:

- **Conducta en pandemia:** cuánto se juntaba con gente / salía (*w2covid_gather, w2covid_out*).
- **Empatía:** tendencia a ponerse en el lugar del otro (*w2emp_place*).
- **Discernimiento de noticias** y consumo de información política (*w2discern, w3discern, w2p5, w3pe*).

Por qué: No es ideología declarada, pero en el clima de 2020 estas conductas correlacionan 0,2–0,3 con el voto (el comportamiento frente al COVID se volvió señal partidaria). Suma +5 puntos.

■ 3a · + afecto identitario / cultura · accuracy 0,851

Termómetros de sentimiento (0–100) hacia **grupos sociales y culturales**:

- gays, personas trans, feministas, ateos, musulmanes (*w2ftgay, w2fttrans, w2ftfeminists, w3ftatheists, w3ftmuslims*).

Por qué: Actitudes culturales estables —no “política” en sentido estricto— pero correlacionan 0,4–0,5. Cómo te sentís hacia grupos identitarios ya predice bastante. Suma +5 puntos.

■ 3b · + posiciones de issues · accuracy 0,926

Opiniones **concretas sobre temas de política pública**:

- **Termómetros económico-institucionales**: socialistas, capitalistas, policía, periodistas (*w2ftsocialists*, *w2ftcapitalists*, *w2ftpolicie*, *w2ftjournal*).
- **Posiciones**: control de armas, cambio climático, aborto, Obamacare/ACA, deportación-inmigración (*w2gundiff*, *w2c_self*, *w3abortion*, *w2aca*, *w2deport*).

Por qué: Acá está el salto grande: +7,5 puntos con apenas 14 variables. Correlación 0,5–0,66 con el voto. Las opiniones sobre issues concretos son el predictor decisivo, no la demografía.

■ 3c · + ideología explícita · accuracy 0,933

La etiqueta ideológica más directa:

- **Autoubicación izquierda–derecha** (*w2lcself*, *w3lcself*).
- **Cosmovisión simbólica**: resentimiento racial y sexismo moderno (*w2rr1*, *w2rr2*, *w2w1*, *w2w2*).

Por qué: Correlación altísima (*lcself* $\approx$ 0,73), pero **redundante**: solo +1 punto sobre los issues. “Soy conservador” ya está implícito en qué opina la persona sobre aborto, clima y armas.

■ 4 · + actitudes a candidatos (near-leakage) · accuracy 0,971

Las actitudes más explícitas hacia los candidatos, **depurando de entrada** la paradata (tiempos de respuesta, orden de ítems) y el leak directo del voto (intención de voto, voto a otros cargos, primaria):


- termómetros a Trump / Biden / partidos, aprobación presidencial, “qué partido es mejor en X”.

Por qué: Son 282 variables (172 más que el nivel anterior) que aportan apenas +4 puntos: confirma que la señal útil ya estaba en los issues. Estas actitudes son *proxies de preferencia* (sentir calor por Trump es casi declarar el voto), así que el nivel se usa como **techo de referencia, no en el modelo final**.


Variables más importantes por escenario

Importancia por **permutación** (no MDI): se mide cuántos puntos de accuracy se **pierden** al desordenar al azar cada variable en el conjunto de test. Es honesta con la redundancia —una variable cuya información ya está en otra no recibe crédito—. XGBoost, n_repeats=10. La barra es relativa al máximo de cada escenario.


■ Apolítico real · accuracy 0,750




■ + conducta polarizada · accuracy 0,801



■ + afecto identitario · accuracy 0,851



■ + posiciones de issues · accuracy 0,926



■ + ideología explícita · accuracy 0,933


Autoubicación izq-der	■■■■■■■■■■ 2.5
Term. a la policía	■■■■■■■■■■ 2.3
Term. a periodistas	■■■■■■■■■■ 2.1
Control de armas (w3)	■■■■■■ 1.1
Control de armas	■■■■ 0.8
Resentimiento racial (2)	■■■■ 0.8
Resentimiento racial (1)	■■■■ 0.8
Autoubicación izq-der (w3)	■■■■ 0.8

■ + actitudes a candidatos · accuracy 0,971

Term. a Trump	■■■■■■■■■■ 1.4
Aprobación a Trump (presidente)	■■■■ 0.6
Term. a Biden	■■■■ 0.6
Term. a Demócratas	■■■■ 0.4
Destitución de Trump (impeachment)	■■■■ 0.4
Term. a inmigrantes	■■■ 0.3
Term. a Sanders	■■■ 0.2
Manejo del COVID en EE.UU.	■■■ 0.2

Lectura: en el nivel **apolítico** mandan el ser **evangélico** y la **raza/etnia** (la espina dorsal sociológica del voto). Al sumar issues, los **termómetros a policía, periodistas y socialistas** y el **control de armas** pasan al frente. En el nivel **near-leakage** domina el **termómetro a Trump** (-1,4 pts) y la **aprobación presidencial**: son actitudes hacia los candidatos, casi sinónimos del voto — por eso este nivel es solo **techo de referencia**.

Resumen visual



La pendiente es empinada al pasar a issues (pocas variables, gran salto) y casi plana después (muchas variables, poco aporte).

¿Y si el voto tiene más de dos clases?

Hasta acá modelamos **Trump vs Biden** (binario). Probamos dos variantes multiclase y **ninguna funciona bien** — por la misma razón: el **desbalance de clases**. El *accuracy* engaña (queda cerca de “adivinar siempre la mayoría”); el **f1_macro** y el **recall por clase** lo exponen. Modelo: HistGradientBoosting, holdout ×5.

1 · Voto general con la clase “Otro” (3 clases)

Trump / Biden / Otro. accuracy **0.935** · f1_macro **0.676** · baseline “siempre la mayoría” 0.565.

Clase	n (casos)	% del total	Recall (acierto)
Biden	2561	56.5%	0.98
Trump	1801	39.7%	0.96
Otro	171	3.8%	0.07

El accuracy alto (0,935) es un **espejismo**: viene de que Trump y Biden se predicen casi perfecto. La clase **“Otro” (171 casos, 3,8%) tiene recall 0,07** — el modelo casi nunca la acierta. Los terceros partidos son ~2% del electorado y no tienen un perfil propio: se reparten entre los dos grandes. **Por eso modelamos el problema como binario.**

2 · Primaria demócrata (vote20cand, 7 candidatos)

Biden / Sanders / Warren / Buttigieg / Klobuchar / Bloomberg / Otro. accuracy **0.697** · f1_macro **0.234** · baseline 0.629.

Clase	n (casos)	% del total	Recall (acierto)
Biden	1628	62.9%	0.93
Sanders	482	18.6%	0.55
Warren	173	6.7%	0.07
Otro	108	4.2%	0.22
Buttigieg	88	3.4%	0.00
Klobuchar	56	2.2%	0.00
Bloomberg	52	2.0%	0.00

Acá el f1_macro se **derrumba a 0,23**. El modelo solo aprende **Biden** (recall 0,93) y a medias **Sanders** (0,55); **Bloomberg, Buttigieg y Klobuchar tienen recall 0,00** — con <90 casos cada uno, no hay con qué aprenderlos. La primaria *fue*, en los hechos, Biden vs Sanders. **Ninguna técnica rescata una clase de 52 ejemplos solapada con una mayoría de 1.628.**

Lección: con clases minoritarias el accuracy miente; hay que mirar f1_macro y recall por clase. El cuello de botella es la **cantidad de casos**, no el método.

Predecir el voto vs predecir el partidismo

¿Es más fácil predecir **a quién votó** o **con qué partido se identifica** (pid7x)? Con las **mismas features** (solo demografía + uso de redes, sin actitudes políticas) y el mismo modelo (XGBoost, holdout ×5), comparamos. Sin la clase “Otro” del voto.

Qué se predice	Clases	n	Accuracy	f1_macro
Voto (Trump vs Biden)	2	4362	0.727 ± 0.011	0.715
Partidismo (Dem vs Rep)	2	5097	0.718 ± 0.013	0.714
Partidismo (Dem/Indep/Rep)	3	5743	0.641 ± 0.013	0.490

(features = 41 variables de demografía + redes)

Voto (0,727) y partidismo binario (0,718) dan prácticamente lo mismo —la diferencia cae dentro del desvío—. No es casualidad: **voto e identidad partidaria coinciden en ~94% de las personas** (correlación de Spearman 0,78), así que para un modelo son **casi la misma variable**. El techo de ~0,72 no es una propiedad “del voto” ni “del partidismo”: es el **límite de lo que la demografía sola puede decir**.

Cuando se agregan los **independientes** (3 clases), el accuracy cae a **0,641** y el f1_macro a 0,49: los independientes no tienen un perfil demográfico propio (están “en el medio”), así que son los más difíciles de clasificar — el mismo fenómeno que veíamos en los votantes cruzados.

Optimización de hiperparámetros

Los **parámetros** los aprende el modelo de los datos (los cortes de los árboles); los **hiperparámetros** se fijan antes y controlan *cómo* aprende (profundidad, regularización...). Optimizarlos = probar combinaciones y quedarse con la que mejor generaliza.

El protocolo: split 60 / 20 / 20

Partimos en **tres**: **train (60%)** para entrenar cada candidato, **validation (20%)** para elegir el mejor, y **test (20%)** para el número final. **El test no se toca durante la búsqueda.** Si eligiéramos los hiperparámetros mirando el test, nos sobreajustaríamos a él y el resultado saldría optimista; el *validation* es el “test de mentira” que sí podemos mirar, y el test real queda virgen para un reporte honesto.

La búsqueda: random search + early stopping

Probamos **40 combinaciones al azar** del espacio (no todas: el grid completo son 8.640). El *random search* es más eficiente que el grid porque muchos hiperparámetros casi no influyen. El número de árboles no se busca a mano: se fija alto (2.000) y el **early stopping** lo corta solo cuando el error en *validation* deja de mejorar (50 rondas).

Hiperparámetro	Valores probados	Qué controla
max_depth	2, 3, 4, 6, 8	profundidad → interacciones que capta
learning_rate	0,01 – 0,1	cuánto aporta cada árbol
min_child_weight	1, 3, 5, 10	mínimo de datos por hoja (poda)
subsample	0,6 / 0,8 / 1,0	fracción de filas por árbol
colsample_bytree	0,6 / 0,8 / 1,0	fracción de columnas por árbol
reg_lambda	0, 1, 2, 5	regularización L2
reg_alpha	0, 0,5, 1	regularización L1

Resultados (XGBoost, reporte en test intacto)

Set de features	default	tuneado	val	Δ
Completo (techo ~0,97)	0.964	0.966	0.977	+0.001
Demografía+redes (~0,72)	0.726	0.729	0.732	+0.002

Mejor config completo: depth=2, lr=0.1, min_child=1, sub=0.8, col=0.6, λ =2.0, α =1.0, árboles=114.

Mejor config demo+redes: depth=2, lr=0.1, min_child=5, sub=0.6, col=0.6, λ =5.0, α =0.0, árboles=185.

Tres conclusiones

1 · El tuning mueve milésimas (+0,002). En el techo alto y en el bajo por igual: el límite es la **señal de los datos**, no los hiperparámetros.

2 · La búsqueda eligió sola el modelo más simple (max_depth = 2 en ambos sets). Con poca estructura que exprimir, los árboles chatos ganan — y el early stopping bajó los árboles de 500 a 114/185.

3 · Validation sobreestima. En el set completo, validation dio **0.977** pero el test honesto fue **0.966** (~1 punto de diferencia). El val está “elegido” (es el máximo de 40 candidatos), así que infla; por eso se reporta el **test intacto**. Esto es justo lo que el protocolo 60/20/20 está diseñado para evitar.

Conclusiones

El proyecto no buscó solo “predecir el voto”, sino entender **qué tipo de información** lo determina y dónde está el límite de lo predecible. Los resultados convergen en cinco ideas:

1 · El voto se explica por las actitudes políticas, no por la demografía.

Saber edad, raza, educación y qué redes usás deja $\sim 0,72-0,75$. Lo que lleva el accuracy a $>0,93$ son las **posiciones concretas sobre issues** (aborto, clima, armas): el salto grande lo dan 14 variables, no la masa de datos sociodemográficos.

2 · La ideología vive en las posiciones, no en la etiqueta.

Conocidas las opiniones sobre los issues, agregar la autoubicación izquierda-derecha aporta apenas +1 punto: “soy conservador” es casi información redundante de lo que la persona ya opina.

3 · El cuello de botella es la información, no el modelo.

El tuning de hiperparámetros mueve milésimas; LogReg, RandomForest y XGBoost convergen cuando hay señal; y reducir el train de 75% a 60% no cambia el resultado. Lo único que movió la aguja fue **sumar información de otro tipo**.

4 · Hay un techo irreducible: los votantes “incoherentes”.

El $\sim 3-6\%$ de error no es azar ni falla del modelo: son **votantes cruzados** (votan contra su partido e ideología), que explican hasta el 76% de los errores. Su voto no es función de las actitudes medidas, así que **ningún modelo puede llegar a 100%**.

5 · Disciplina metodológica.

Distinguir *leakage* de predisposición estable; mirar `f1_macro` y `recall` por clase ante el desbalance (las minorías son inmodelables); reportar con barras de error y no sobre-leer un único split. Modelamos el problema como **binario** (Trump vs Biden) por estas razones, no por comodidad.

En una frase: en un electorado polarizado, el voto es casi un sinónimo de las actitudes políticas —tanto que conocerlas alcanza para predecirlo con $>0,93$ —, y lo que queda sin explicar no es ignorancia del modelo sino la parte genuinamente idiosincrática de la decisión humana.

Referencias

- American National Election Studies (2023). *ANES 2020-2022 Social Media Study* [dataset y user guide / codebook]. www.electionstudies.org.
- Bergstra, J. & Bengio, Y. (2012). *Random Search for Hyper-Parameter Optimization*. Journal of Machine Learning Research, 13, 281–305.
- Chen, T. & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of KDD '16, 785–794.
- Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.